# Bajesovska optimizacija

Ognjen Nešković 9/2022
Pavle Sekešan 87/2022

Projekat u okviru kursa Racunarska inteligencija

Februar 2026

# Sadržaj

**1 Uvod** **3**

1.1 Ograničenja . . . . . 3

**2 Bajesovska optimizacija GP-EI** **4**

2.1 GP Regresija . . . . . 4

2.2 Akviziciona funkcija, EI . . . . . 6

**3 Implementacija** **6**

**4 Eksperimenti** **6**

4.1 Postavka . . . . . 6

4.2 Rezultati . . . . . 6

4.3 Diskusija . . . . . 6

**5 Zakljucak** **6**

# 1 Uvod

Bajesovska optimizacija (*Bayesian optimization*) je porodica algoritama za *Black box*[1] optimizaciju funkcija. Bajesovska optimizacija se primenjuje kao vrlo generalna metoda u slučajevima kada ne možemo pretpostaviti ništa dodatno u vezi funkcije koja se optimizuje - u praksi ova metoda optimizacije se primenjuje kada je funkcija neprekidna, nije diferencijabilna (ili je presporo evaluirati njen izvod), skupa da se evaluira i domen funkcije je nisko-dimenzion $d \leq 20$ (Frazier 2018.). Česta upotreba Bajesovske optimizacije je kao tehnika za nalaženje optimalnih hiperparametara modela koji se koriste u mašinskom učenju — broj i veličina slojeva neuronske mreže, aktivacione funkcije, maksimalna dubina stabala odlučivanja...

Osnovna ideja algoritama Bajesovske optimizacije je sledeća: Kako funkcija $f$ koja se optimizuje nije poznata tretiraćemo je kao nasumičnu. Postavićemo apriornu raspodelu nad $f$, kada izaberemo novu tačku i evaluiramo funkciju u toj tački ažuriraćemo raspodelu kako bi dobili aposteriornu raspodelu. Na osnovu nekog broja evaluacija funkcije $f$ i tačaka u kojima je evaluirana se dobija raspodela nad $f$. Ova raspodela nam daje u suštini *surogat* funkciju. Ova *surogat* funkcija je aproksimacija koja je značajno lakša da se evaluira nego $f$. Korisno je napomenuti da ovo nije suštinski za tehnike Bajesovske optimizacije. Postoje i druge optimizacione metode koje se zasnivaju na pronalaženju i optimizaciji *surogat* funkcija (Booker i dr. 1999.).

Algoritmi zasnovani na idejama Bajesovske optimizacije se suštinski razlikuju u tome kako postavljaju raspodelu nad $f$ i kako biraju narednu tačku za evaluaciju na osnovu postavljene raspodele. Metoda koja je implementirana u ovom radu se zasniva na tehnici GP (*Gaussian Process*) regression za određivanje raspodele nad $f$. Na osnovu raspodele koja je određena nad $f$ potrebno je odabrati sledeću tačku u kojoj će se evaluirati $f$. Suštinski, prilikom odabira naredne tačke potrebno je balansirati koliko se istražuje deo prostora gde je nesigurnost funkcije velika i koliko se eksploatišu delovi funkcije za koje je već poznato da su potencijalno blizu optimalne vrednosti. U ovom radu je u te svrhe implementiran tzv. princip očekivanog poboljšanja (EI - Expected Improvement).

## 1.1 Ograničenja

Metoda Bajesovske optimizacije koja je opisana i implementirana u okviru ovog rada rešava problem:

$$\min_{x \in A} f(x)$$

Metoda se može primeniti ukoliko je ispunjeno sledeće:

- Za neko $x$ je lako proveriti da li pripada domenu $A$. Konkretno u ovoj implementaciji se pretpostavlja da je domen oblika $\{x \in \mathbb{R}^d | l_i \leq x \leq h_i\}$.
- Funkcija $f$ je neprekidna

[1] U ovom kontekstu Black box optimizacija odnosi se na optimizaciju funkcije bez poznavanja ikakvih njenih svojstava osim vrednosti u odabranim tačkama.

# 2 Bajesovska optimizacija GP-EI

## 2.1 GP Regresija

GP (Gaussian process) regresija je metoda interpolacije zasnovana na *Gausovim procesima*. GP regresija je čest pristup za određivanje surogat funkcije u Bajesovskoj optimizaciji. Neformalno govoreći, pomoću GP regresije odredićemo očekivanu vrednost funkcije na osnovu prethodno viđenih podataka i takođe možemo odrediti varijansu pa i interval poverenja oko te očekivane vrednosti. Veća varijansa odnosno širi interval poverenja znači da „nismo sigurni" kako funkcija izgleda u tom delu, a manja varijansa da smo sigurniji u oblik funkcije. Videti 1 za primer.

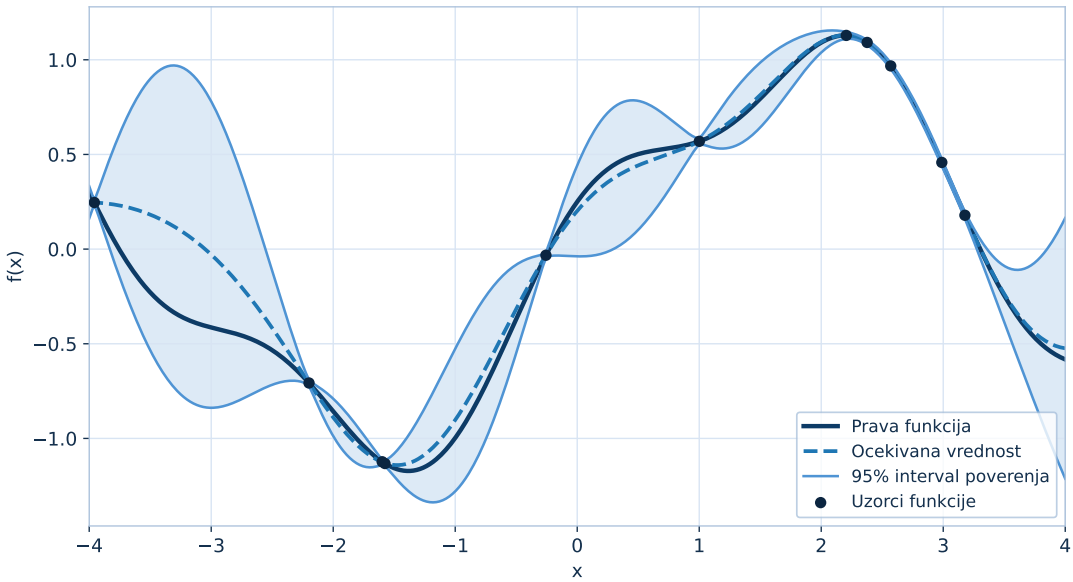


Slika 1: Primer GP regresije primenjene na jednodimenzionoj funkciji.

Formalnije, kako nemamo nikakvih informacija o funkciji osim par vrednosti u uzorkovanim tačkama pretpostavićemo da je funkcija $f$ Gausov proces.

> **Definicija: Gausov proces**
> Gausov proces je stohastički proces takav da za svaki konačni niz $x_1, ..., x_n$ važi $(x_1, ..., x_n) \sim \mathcal{N}_n(\mu, \Sigma)$. Gde su: $\mu = (\mathbb{E}[X_1], ..., \mathbb{E}[X_n])$ i $\Sigma_{i,j} = \mathrm{Cov}[X_i, X_j]$

U slučaju GP regresije pretpostavka je da $f(x_1), ..., f(x_n) \sim \mathcal{N}_n(\mu(X), \Sigma(X))$. Dodatno, često se uzima da je $\mu(X) = 0$. Matrica kovarijansi $\Sigma$ mora biti pozitivno semidefinitna kako bi normalna raspodela bila ispravno definisana. Umesto matrice kovarijansi koristi se pozitivno semidefinitni kernel kao na primer: RBF kernel, polinomski, linearni... Matricu kovarijansi modelujemo na ovaj način jer želimo da možemo da vršimo ekstrapolaciju van tačaka u kojima je uzorkovana funkcija, a za to je potrebno da možemo da odredimo vrednost kovarijanse između uzorkovane tačke $x_i$ i neke proizvoljne tačke $x$.

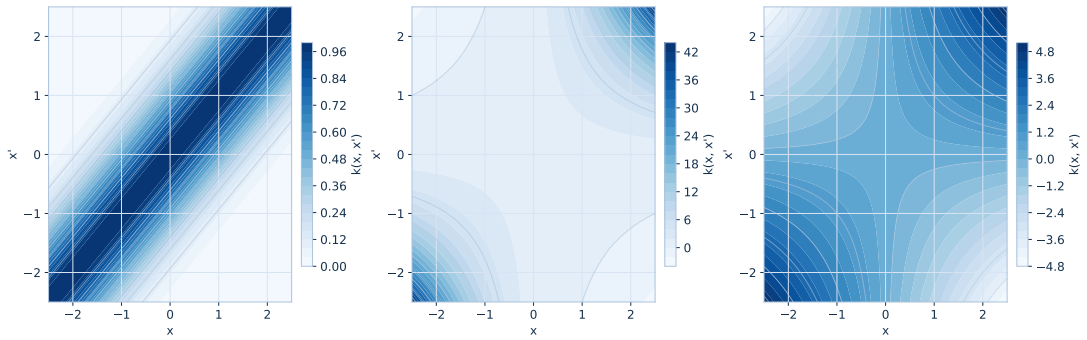


Slika 2: Primer nekih često korišćenih kernela: RBF kernel ($l = 0.9, a = 1.0$), polinomski kernel ($\alpha = 0.4, c = 1.0, \text{stepen} = 3$) i linearni kernel ($\sigma_v^2 = 0.8, \sigma_b^2 = 0.2$).

Kako bismo odredili očekivanu vrednost funkcije i varijansu potrebno je da odredimo aposteriornu raspodelu: $f(x)|Y = f(X)$, gde su: $X$ do sada uzorkovane tačke, a $Y$ vrednosti funkcije $f$ u tim tačkama. Formalnije, pretpostavili smo da je $Y \sim \mathcal{N}_n(0, K(X, X))$. Pa će važiti i za novu tačku $(y = f(x), x)$:

$$\begin{pmatrix} y \\ Y \end{pmatrix} \sim \mathcal{N}\left(\begin{pmatrix} 0 \\ 0 \end{pmatrix}, \begin{pmatrix} K(x,x) & K(X,x)^\top \\ K(X,x) & K(X,X) \end{pmatrix}\right)$$

Želimo da odredimo raspodelu $y|Y$. Za višedimenzione normalne raspodele date u obliku:

$$\begin{pmatrix} x \\ y \end{pmatrix} \sim \mathcal{N}\left(\begin{pmatrix} \mu_x \\ \mu_y \end{pmatrix}, \begin{pmatrix} A & C^\top \\ C & B \end{pmatrix}\right)$$

Je poznato (Williams i Rasmussen 2006.) da važi:

$$x|y \sim \mathcal{N}(\mu_x + C^\top B^{-1}(y - \mu_y), A - C^\top B^{-1} C)$$

Što je u našem slučaju:

$$y|Y \sim \mathcal{N}(K(X,x)^\top K(X,X)^{-1} Y, K(x,x) - K(X,x)^\top K(X,X)^{-1} K(X,x))$$

Što možemo da zapišemo i kao

$$\begin{aligned} \mu(x) &= K(X,x)^\top K(X,X)^{-1} Y \\ \sigma^2(x) &= K(x,x) - K(X,x)^\top K(X,X)^{-1} K(X,x) \end{aligned}$$

Ovim smo dobili aposteriori raspodelu što ćemo koristiti nadalje kako bismo odredili najpovoljniji deo prostora da uzorkujemo narednu tačku.

### 2.2 Akviziciona funkcija, EI

## 3 Implementacija

## 4 Eksperimenti

### 4.1 Postavka

### 4.2 Rezultati

### 4.3 Diskusija

## 5 Zakljucak

## Literatura


Booker, Andrew J i dr. (1999.). „A rigorous framework for optimization of expensive functions by surrogates". U: *Structural optimization* 17.1, str. 1–13.

Williams, Christopher KI i Carl Edward Rasmussen (2006.). *Gaussian processes for machine learning*. Sv. 2. 3. MIT press Cambridge, MA.

Frazier, Peter I. (2018.). *A Tutorial on Bayesian Optimization*. arXiv: `1807.02811 [stat.ML]`. URL: `https://arxiv.org/abs/1807.02811`.