Bajesovska optimizacija

Ognjen Nešković 9/2022
Pavle Sekešan 87/2022

Projekat u okviru kursa Racunarska inteligencija

Februar 2026

Sadržaj

1 Uvod **3**

1.1 Ograničenja 3

2 Bajesovska optimizacija GP-EI **4**

2.1 GP Regresija 4

2.2 Akviziciona funkcija, EI 5

3 Implementacija **7**

3.1 Opšta procedura optimizacije 7

3.2 Implementacija GP regresije 10

4 Eksperimenti **11**

4.1 Postavka 11

4.2 Rezultati 11

4.3 Diskusija 11

5 Zakljucak **11**

1 Uvod

Bajesovska optimizacija (*Bayesian optimization*) je porodica algoritama za *Black box*[1] optimizaciju funkcija. Bajesovska optimizacija se primenjuje kao vrlo generalna metoda u slučajevima kada ne možemo pretpostaviti ništa dodatno u vezi funkcije koja se optimizuje - u praksi ova metoda optimizacije se primenjuje kada je funkcija neprekidna, nije diferencijabilna (ili je presporo evaluirati njen izvod), skupa da se evaluira i domen funkcije je nisko-dimenzion $d \leq 20$ (Frazier 2018.). Česta upotreba Bajesovske optimizacije je kao tehnika za nalaženje optimalnih hiperparametara modela koji se koriste u mašinskom učenju — broj i veličina slojeva neuronske mreže, aktivacione funkcije, maksimalna dubina stabala odlučivanja...

Osnovna ideja algoritama Bajesovske optimizacije je sledeća: Kako funkcija f koja se optimizuje nije poznata tretiraćemo je kao nasumičnu. Postavićemo apriornu raspodelu nad f, kada izaberemo novu tačku i evaluiramo funkciju u toj tački ažuriraćemo raspodelu kako bi dobili aposteriornu raspodelu. Na osnovu nekog broja evaluacija funkcije f i tačaka u kojima je evaluirana se dobija raspodela nad f. Ova raspodela nam daje u suštini *surogat* funkciju. Ova *surogat* funkcija je aproksimacija koja je značajno lakša da se evaluira nego f. Korisno je napomenuti da ovo nije suštinski za tehnike Bajesovske optimizacije. Postoje i druge optimizacione metode koje se zasnivaju na pronalaženju i optimizaciji *surogat* funkcija (Booker i dr. 1999.).

Algoritmi zasnovani na idejama Bajesovske optimizacije se suštinski razlikuju u tome kako postavljaju raspodelu nad f i kako biraju narednu tačku za evaluaciju na osnovu postavljene raspodele. Metoda koja je implementirana u ovom radu se zasniva na tehnici GP (*Gaussian Process*) regression za određivanje raspodele nad f. Na osnovu raspodele koja je određena nad f potrebno je odabrati sledeću tačku u kojoj će se evaluirati f. Suštinski, prilikom odabira naredne tačke potrebno je balansirati koliko se istražuje deo prostora gde je nesigurnost funkcije velika i koliko se eksploatišu delovi funkcije za koje je već poznato da su potencijalno blizu optimalne vrednosti. U ovom radu je u te svrhe implementiran tzv. princip očekivanog poboljšanja (EI - Expected Improvement).

1.1 Ograničenja

Metoda Bajesovske optimizacije koja je opisana i implementirana u okviru ovog rada rešava problem:

$$\min_{x \in A} f(x)$$

Metoda se može primeniti ukoliko je ispunjeno sledeće:

- Za neko x je lako proveriti da li pripada domenu A. Konkretno u ovoj implementaciji se pretpostavlja da je domen oblika $\{x \in \mathbb{R}^d | l_i \leq x \leq h_i\}$.
- Funkcija f je neprekidna

[1] U ovom kontekstu Black box optimizacija odnosi se na optimizaciju funkcije bez poznavanja ikakvih njenih svojstava osim vrednosti u odabranim tačkama.

2 Bajesovska optimizacija GP-EI

2.1 GP Regresija

GP (Gaussian process) regresija je metoda interpolacije zasnovana na *Gausovim procesima*. GP regresija je čest pristup za određivanje surogat funkcije u Bajesovskoj optimizaciji. Neformalno govoreći, pomoću GP regresije odredićemo očekivanu vrednost funkcije na osnovu prethodno viđenih podataka i takođe možemo odrediti varijansu pa i interval poverenja oko te očekivane vrednosti. Veća varijansa odnosno širi interval poverenja znači da „nismo sigurni" kako funkcija izgleda u tom delu, a manja varijansa da smo sigurniji u oblik funkcije. Videti 1 za primer.

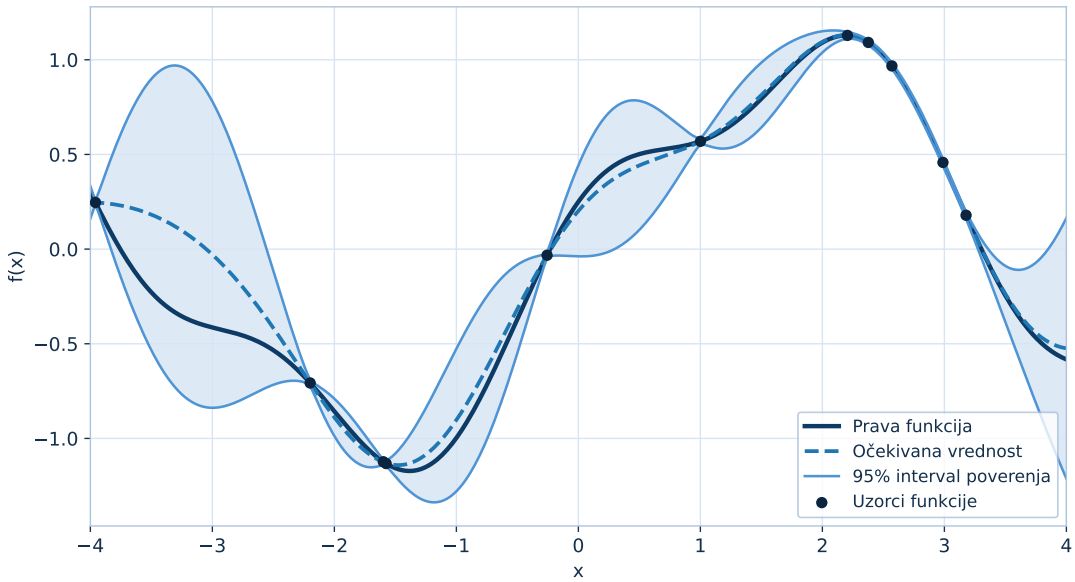

Slika 1: Primer GP regresije primenjene na jednodimenzionoj funkciji.

Formalnije, kako nemamo nikakvih informacija o funkciji osim par vrednosti u uzorkovanim tačkama pretpostavićemo da je funkcija f Gausov proces.

> **Definicija: Gausov proces**
> Gausov proces je stohastički proces takav da za svaki konačni niz $x_1, ..., x_n$ važi $(x_1, ..., x_n) \sim \mathcal{N}_n(\mu, \Sigma)$. Gde su: $\mu = (\mathbb{E}[X_1], ..., \mathbb{E}[X_n])$ i $\Sigma_{i,j} = \mathrm{Cov}[X_i, X_j]$

U slučaju GP regresije pretpostavka je da $f(x_1), ..., f(x_n) \sim \mathcal{N}_n(\mu(X), \Sigma(X))$. Dodatno, često se uzima da je $\mu(X) = 0$. Matrica kovarijansi Σ mora biti pozitivno semidefinitna kako bi normalna raspodela bila ispravno definisana. Umesto matrice kovarijansi koristi se pozitivno semidefinitni kernel kao na primer: RBF kernel, polinomski, linearni... Matricu kovarijansi modelujemo na ovaj način jer želimo da možemo da vršimo ekstrapolaciju van tačaka u kojima je uzorkovana funkcija, a za to je potrebno da možemo da odredimo vrednost kovarijanse između uzorkovane tačke x_i i neke proizvoljne tačke x.

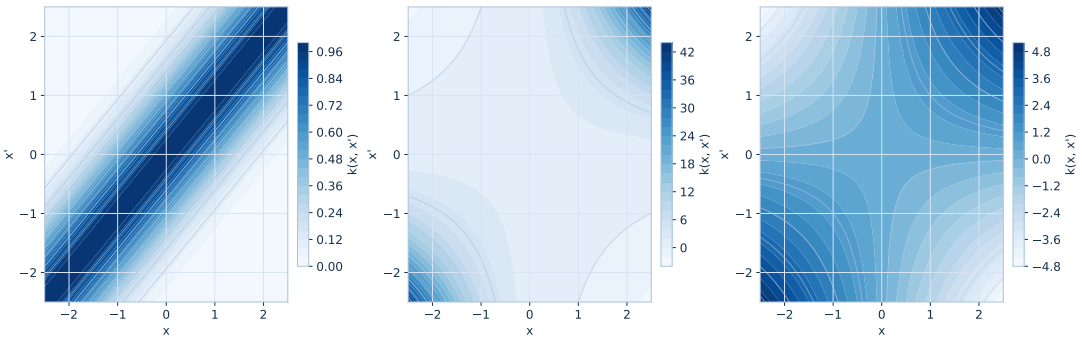

Slika 2: Primer nekih često korišćenih kernela: RBF kernel ($l = 0.9, a = 1.0$), polinomski kernel ($\alpha = 0.4, c = 1.0, \text{stepen} = 3$) i linearni kernel ($\sigma_v^2 = 0.8, \sigma_b^2 = 0.2$).

Kako bismo odredili očekivanu vrednost funkcije i varijansu potrebno je da odredimo aposteriornu raspodelu: $f(x)|Y = f(X)$, gde su: X do sada uzorkovane tačke, a Y vrednosti funkcije f u tim tačkama. Formalnije, pretpostavili smo da je $Y \sim \mathcal{N}_n(0, K(X, X))$. Pa će važiti i za novu tačku ($y = f(x), x$):

$$\begin{pmatrix} y \\ Y \end{pmatrix} \sim \mathcal{N}\left(\begin{pmatrix} 0 \\ 0 \end{pmatrix}, \begin{pmatrix} K(x,x) & K(X,x)^\top \\ K(X,x) & K(X,X) \end{pmatrix}\right)$$

Želimo da odredimo raspodelu $y|Y$. Za višedimenzione normalne raspodele date u obliku:

$$\begin{pmatrix} x \\ y \end{pmatrix} \sim \mathcal{N}\left(\begin{pmatrix} \mu_x \\ \mu_y \end{pmatrix}, \begin{pmatrix} A & C^\top \\ C & B \end{pmatrix}\right)$$

Je poznato (Williams i Rasmussen 2006.) da važi:

$$x|y \sim \mathcal{N}(\mu_x + C^\top B^{-1}(y - \mu_y), A - C^\top B^{-1} C)$$

Što je u našem slučaju:

$$y|Y \sim \mathcal{N}(K(X,x)^\top K(X,X)^{-1} Y, K(x,x) - K(X,x)^\top K(X,X)^{-1} K(X,x))$$

Što možemo da zapišemo i kao

$$\begin{aligned} \mu(x) &= K(X,x)^\top K(X,X)^{-1} Y \\ \sigma^2(x) &= K(x,x) - K(X,x)^\top K(X,X)^{-1} K(X,x) \end{aligned} \tag{1}$$

Ovim smo dobili aposteriori raspodelu što ćemo koristiti nadalje kako bismo odredili najpovoljniji deo prostora da uzorkujemo narednu tačku.

2.2 Akviziciona funkcija, EI

GP regresijom dobijamo aposteriornu raspodelu $f(x) \mid Y$. Sledeći korak u Bajesovskoj optimizaciji je da na osnovu tih informacija izaberemo novu tačku za evaluiranje f. Da bismo doneli

tu odluku potrebno je da balansiramo između „istraživanja” delova funkcije koji nam nisu dobro poznati (velika varijansa) i eksploatisanja delova funkcije gde imamo manju varijansu, a veliku očekivanu vrednost (Explore - Exploit dilemma). U te svrhe koristićemo tzv. Akvizicionu funkciju (Acquisition function).

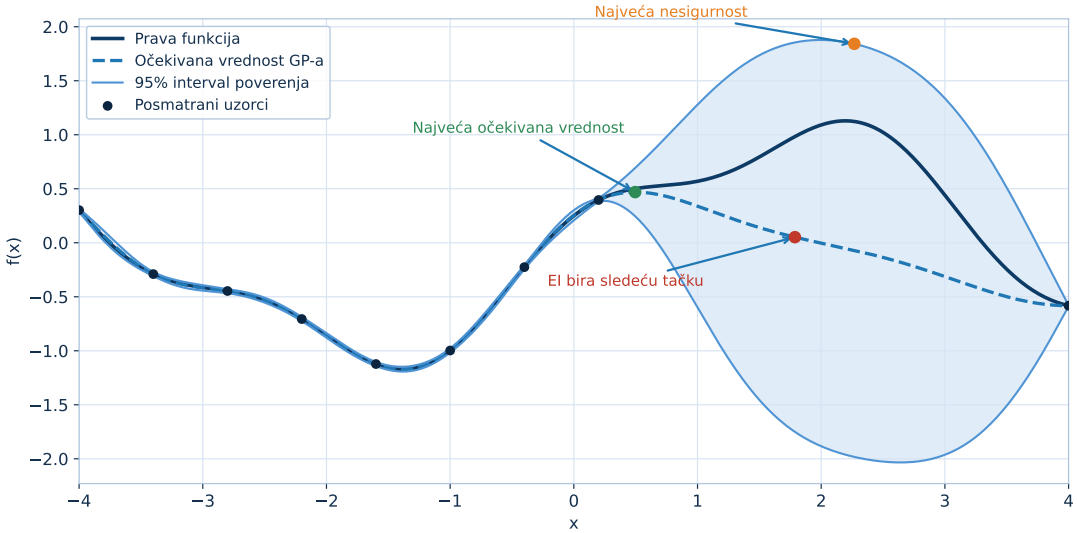

Slika 3: Explore-Exploit dilema u Bajesovskoj optimizaciji

U ovom radu koristimo princip očekivanog poboljšanja (EI – *Expected Improvement*). Neka je trenutna najbolja viđena vrednost $m = \min_{i=1,\dots,n}(y_i)$ (minimizujemo f). Za problem minimizacije prirodno je definisati poboljšanje u tački x kao

$$I(x) = \max(m - f(x), 0).$$

Očekivano poboljšanje je onda:

$$\mathrm{EI}(x) = \mathbb{E}[I(x) \mid Y] = \mathbb{E}[\max(m - f(x), 0) \mid Y].$$

Označimo slučajnu promenljivu

$$F := f(x) \mid Y \sim \mathcal{N}(\mu(x), \sigma^2(x)).$$

Tada je:

$$\mathrm{EI}(x) = \int_{-\infty}^{+\infty} \max(m - u, 0)\, f_F(u)\, du.$$

Pošto je $\max(m - u, 0) = 0$ za $u > m$, integral se svodi na

$$\mathrm{EI}(x) = \int_{-\infty}^{m} (m - u)\, f_F(u)\, du = m \int_{-\infty}^{m} f_F(u)\, du - \int_{-\infty}^{m} u\, f_F(u)\, du.$$

Kako je $f_F(u)$ funkcija raspodele normalne raspodele $\mathcal{N}(\mu(x), \sigma^2(x))$ ovaj celokupan integral se

može lako svesti na (Snoek, Larochelle i Adams 2012.) :

$$\mathrm{EI}(x) = (m - \mu(x))\Phi(z) + \sigma(x)\phi(z)$$

Gde su Φ - kumulativna funkcija raspodele i ϕ - funkcija raspodele standardne normalne raspodele i $z = \frac{m-\mu(x)}{\sigma(x)}$.

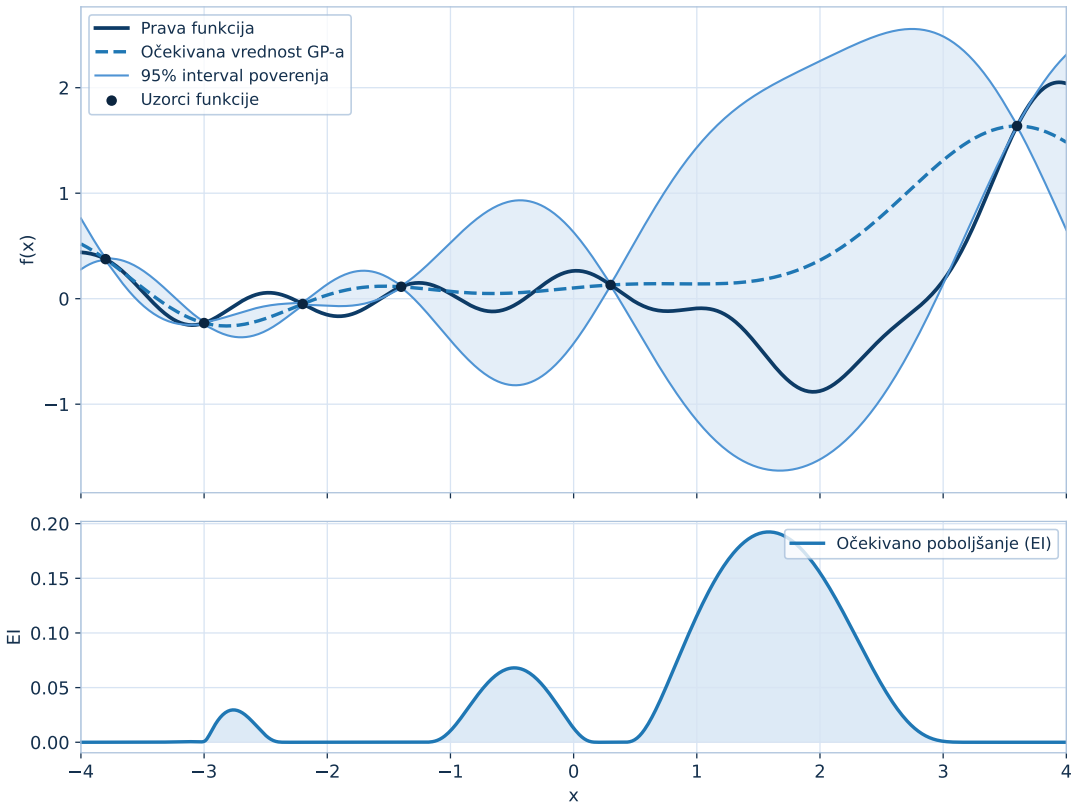

Slika 4: Primer vrednosti očekivanog poboljšanja za jednodimenzionu funkciju

Sledeću tačku biramo maksimizacijom EI na domenu:

$$x_{n+1} = \arg\max_{x \in D} \mathrm{EI}(x).$$

3 Implementacija

3.1 Opšta procedura optimizacije

Kada se Bajesovska optimizacija implementira pomoću Gausovog procesa i akvizicione funkcije očekivanog poboljšanja algoritam je sledeći:

Algoritam 1 Bayesian optimization sa GP i EI (minimizacija)

Ulaz: funkcija f, budžet N, kernel $K(x, y)$

$X = \{\}$
$Y = \{\}$
for $t = 1$ **to** N **do**
    $\mu(x), \sigma(x) \leftarrow \text{fit_gp}(X, Y, K)$
    $x_t \leftarrow \arg\max_{x \in A} \text{EI}(x, \mu(x), \sigma(x))$
    $y_t \leftarrow f(x_t)$
    $X \leftarrow X \cup \{x_t\}, \quad Y \leftarrow Y \cup \{y_t\}$
end for
$x_{\text{best}} \leftarrow \arg\min_{x_i \in X} f(x_i)$
return $x_{\text{best}},\ \min(Y)$

U prethodno opisanom algoritmu 1 ostalo je još da definišemo kako se maksimizuje akviziciona funkcija EI. Kao što je pokazano u 2.2 izračunavanje očekivanog poboljšanja u nekoj datoj tački je relativno jednostavno. Međutim, kao što se može videti na slici 4 sama funkcija EI takođe nema neki povoljan oblik za maksimizaciju u opštem slučaju. Stoga se za maksimizaciju funkcije EI koristi neki drugi optimizacioni metod. Jedna metoda koja se koristi u praksi (Balandat i dr. 2020.) je L-BFGS. L-BFGS se u ovom slučaju pokreće više puta iz različitih početnih tačaka kako bi se što bolje optimizovala funkcija očekivanog poboljšanja. U ovom projektu korišćen je algoritam L-BFGS i pokretan je iz više početnih tačaka.

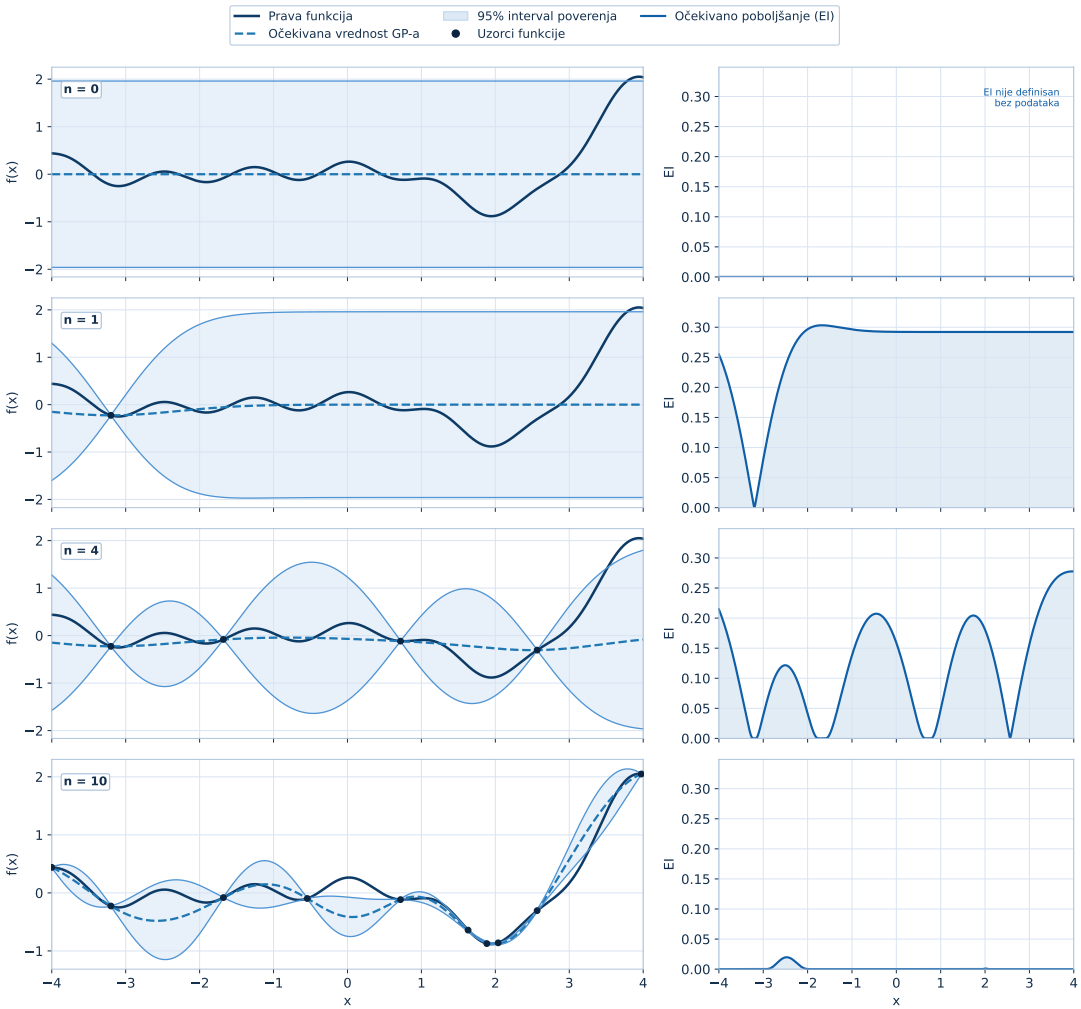

Slika 5: Primer celokupnog izvršavanja algoritma Bajesovske optimizacije za minimizaciju 1D funkcije. Prikaz u trenucima kada je uzorkovano $n = 0, 1, 4$ i 10 tačaka.

3.2 Implementacija GP regresije

Kao što je pokazano u 1 aposteriorna srednja vrednost i varijansa imaju oblik:

$$\mu(x) = m_0 + K(x, X)^\top K(X, X)^{-1}(y - m_0\mathbf{I}), \tag{2}$$

$$\sigma^2(x) = K(x, x) - K(x, X)^\top K(X, X)^{-1} K(x, X). \tag{3}$$

Direktno računanje inverza matrice u (2) i (3) je numerički nepovoljno, pa u implementaciji koristimo ekvivalentnu formu zasnovanu na Cholesky faktorizaciji. Neka je $X \in \mathbb{R}^{n\times d}$ skup tačaka u kojima je uzorkovana funkcija, $y \in \mathbb{R}^n$ vektor vrednosti funkcije u tim tačkama i $K = K(X, X)$. Kako je $K(\cdot, \cdot)$ kernel onda je i matrica K pozitivno semidefinitna pa ima Cholesky dekompoziciju:

$$K = LL^\top.$$

U izrazu (2) pojavljuje se vektor

$$\alpha = K^{-1}(y - m_0\mathbf{I}).$$

Umesto eksplicitnog inverza, α dobijamo rešavanjem dva trougaona sistema:

$$\begin{aligned} Lv &= y - m_0\mathbf{I}, \\ L^\top\alpha &= v. \end{aligned}$$

Predikcija (srednja vrednost). Za bilo koju upitnu tačku x važi

$$\mu(x) = m_0 + K(x, X)^\top \alpha.$$

Predikcija (varijansa). Formula (3) sadrži kvadratnu formu

$$K(x, X)^\top K^{-1} K(x, X).$$

Označimo $k_x = K(x, X) \in \mathbb{R}^n$. Ako rešimo sistem

$$Lw = k_x$$

onda je $w = L^{-1}k_x$ i važi

$$\begin{aligned} k_x^\top K^{-1} k_x &= k_x^\top (LL^\top)^{-1} k_x \\ &= k_x^\top L^{-\top} L^{-1} k_x \\ &= (L^{-1}k_x)^\top (L^{-1}k_x) \\ &= \|L^{-1}k_x\|_2^2 \;=\; \|w\|_2^2. \end{aligned}$$

Pa $\sigma^2(x)$ nalazimo kao:

$$\sigma^2(x) = K(x,x) - \|w\|_2^2, \qquad \text{gde je } Lw = K(x,X).$$

Gde w određujemo rešavanjem trougaonog sistema: $Lw = K(x,X)$.

4 Eksperimenti

4.1 Postavka

4.2 Rezultati

4.3 Diskusija

5 Zakljucak

Literatura

Booker, Andrew J i dr. (1999.). „A rigorous framework for optimization of expensive functions by surrogates". U: *Structural optimization* 17.1, str. 1–13.

Williams, Christopher KI i Carl Edward Rasmussen (2006.). *Gaussian processes for machine learning*. Sv. 2. 3. MIT press Cambridge, MA.

Snoek, Jasper, Hugo Larochelle i Ryan P Adams (2012.). „Practical bayesian optimization of machine learning algorithms". U: *Advances in neural information processing systems* 25.

Frazier, Peter I. (2018.). *A Tutorial on Bayesian Optimization*. arXiv: `1807.02811 [stat.ML]`. URL: `https://arxiv.org/abs/1807.02811`.

Balandat, Maximilian i dr. (2020.). „BoTorch: A framework for efficient Monte-Carlo Bayesian optimization". U: *Advances in neural information processing systems* 33, str. 21524–21538.