Bajesovska optimizacija

Ognjen Nešković 9/2022
Pavle Sekešan 87/2022

Projekat u okviru kursa Računarska inteligencija

Februar 2026

Sadržaj

1 Uvod **3**

1.1 Ograničenja 3

2 Bajesovska optimizacija GP-EI **4**

2.1 GP Regresija 4

2.2 Akviziciona funkcija, EI 5

3 Implementacija **7**

3.1 Opšta procedura optimizacije 7

3.2 Implementacija GP regresije 10

4 Eksperimenti **11**

4.1 Postavka 11

4.2 Rezultati 12

4.3 Diskusija 13

5 Zaključak **13**

1 Uvod

Bajesovska optimizacija (*Bayesian optimization*) je porodica algoritama za *Black box*[1] optimizaciju funkcija. Bajesovska optimizacija se primenjuje kao vrlo opšta metoda u situacijama kada o funkciji koja se optimizuje ne možemo pretpostaviti gotovo ništa dodatno. U praksi se najčešće koristi kada je funkcija neprekidna, nije diferencijabilna (ili je izvod preskup za računanje), skupa je za evaluaciju i definisana je na niskodimenzionom domenu ($d \leq 20$) (Frazier 2018.). Bajesovska optimizacija se često koristi kao tehnika za nalaženje optimalnih hiperparametara modela mašinskog učenja, kao što su broj i veličina slojeva neuronske mreže, izbor aktivacione funkcije i maksimalna dubina stabala odlučivanja.

Osnovna ideja algoritama Bajesovske optimizacije je sledeća: pošto funkcija f nije poznata, tretiramo je kao nasumičnu. Postavlja se apriorna raspodela nad f, a zatim se, nakon svake nove evaluacije funkcije, ta raspodela ažurira u aposteriornu. Na osnovu do tada evaluiranih tačaka dobija se raspodela nad f, odnosno *surogat* funkcija. Ta surogat funkcija predstavlja aproksimaciju koja je značajno jeftinija za evaluaciju od originalne funkcije f. Ovo nije suštinski za tehnike Bajesovske optimizacije, postoje i druge optimizacione metode koje se zasnivaju na pronalaženju i optimizaciji *surogat* funkcija (Booker i dr. 1999.).

Algoritmi zasnovani na idejama Bajesovske optimizacije najviše se razlikuju po tome kako modeluju raspodelu nad f i kako, na osnovu te raspodele, biraju narednu tačku za evaluaciju. Metoda implementirana u ovom radu zasniva se na GP (*Gaussian Process*) regresiji za modelovanje raspodele nad f. Prilikom izbora naredne tačke potrebno je balansirati istraživanje delova prostora u kojima je nesigurnost velika i eksploataciju delova za koje je već poznato da su blizu optimuma. U ovom radu za to koristimo princip očekivanog poboljšanja (EI – *Expected Improvement*).

1.1 Ograničenja

Metoda Bajesovske optimizacije koja je opisana i implementirana u okviru ovog rada rešava problem:

$$\min_{x \in D} f(x)$$

Metoda se može primeniti ukoliko je ispunjeno sledeće:

- Za neko x je lako proveriti da li pripada domenu D. Konkretno u ovoj implementaciji se pretpostavlja da je domen oblika $\{x \in \mathbb{R}^d | l_i \leq x \leq h_i\}$.
- Funkcija f je neprekidna

[1] U ovom kontekstu Black box optimizacija odnosi se na optimizaciju funkcije bez poznavanja ikakvih njenih svojstava osim vrednosti u odabranim tačkama.

2 Bajesovska optimizacija GP-EI

2.1 GP Regresija

GP (Gaussian Process) regresija je metoda interpolacije zasnovana na *Gausovim procesima* i čest je izbor za konstrukciju surogat funkcije u Bajesovskoj optimizaciji. Neformalno, GP regresija nam daje očekivanu vrednost funkcije na osnovu prethodno viđenih podataka, kao i varijansu, odnosno interval poverenja oko te očekivane vrednosti. Veća varijansa (širi interval poverenja) znači da smo manje sigurni u oblik funkcije u tom delu prostora, dok manja varijansa znači veću sigurnost. Videti 1 za primer.

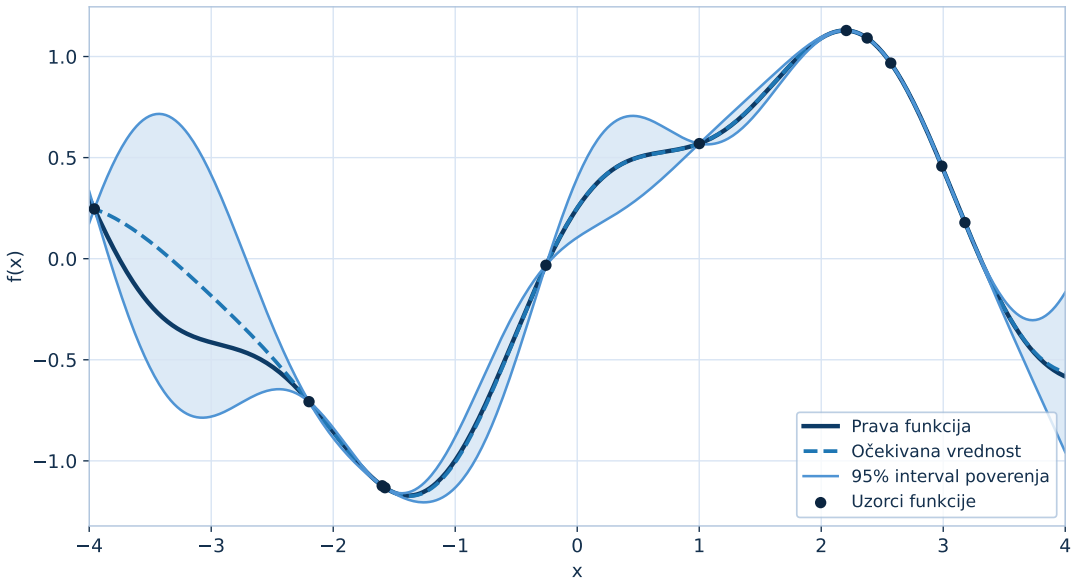

Slika 1: Primer GP regresije primenjene na jednodimenzionoj funkciji.

Formalnije, pošto nemamo informacije o funkciji osim nekoliko vrednosti u uzorkovanim tačkama, pretpostavljamo da je funkcija f Gausov proces.

> **Definicija: Gausov proces**
> Gausov proces je stohastički proces takav da za svaki konačni niz slučajnih promenljivih $X_1, \ldots, X_n$ važi $(X_1, \ldots, X_n) \sim \mathcal{N}_n(\mu, \Sigma)$, gde su $\mu = (\mathbb{E}[X_1], \ldots, \mathbb{E}[X_n])$ i $\Sigma_{i,j} = \mathrm{Cov}[X_i, X_j]$.

U okviru GP regresije pretpostavlja se da važi $f(x_1), \ldots, f(x_n) \sim \mathcal{N}_n(\mu(X), \Sigma(X))$. U praksi se često uzima i $\mu(X) = 0$. Matrica kovarijansi Σ mora biti pozitivno semidefinitna da bi normalna raspodela bila ispravno definisana. Umesto eksplicitnog zadavanja matrice kovarijansi, koristi se pozitivno semidefinitni kernel (npr. RBF, polinomski, linearni). Matricu kovarijansi modelujemo na ovaj način jer želimo da možemo da vršimo ekstrapolaciju van tačaka u kojima je uzorkovana funkcija, a za to je potrebno da možemo da odredimo vrednost kovarijanse između uzorkovane tačke x_i i neke proizvoljne tačke x.

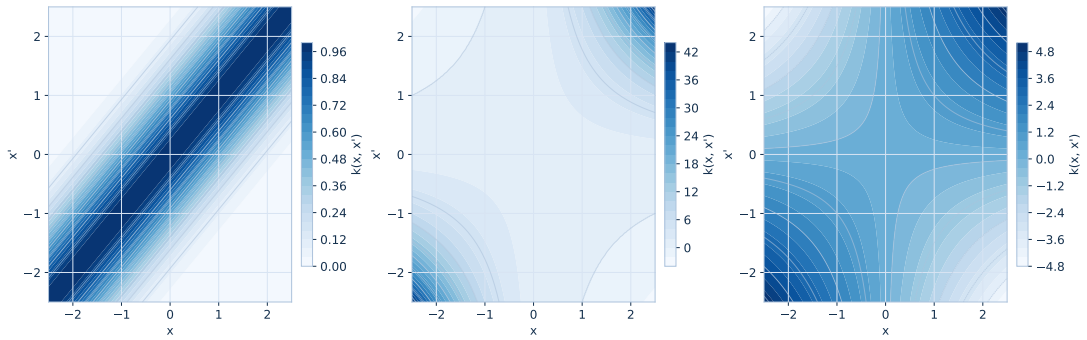

Slika 2: Primer nekih često korišćenih kernela: RBF kernel ($l = 0.9, a = 1.0$), polinomski kernel ($\alpha = 0.4, c = 1.0, \text{stepen} = 3$) i linearni kernel ($\sigma_v^2 = 0.8, \sigma_b^2 = 0.2$).

Da bismo odredili očekivanu vrednost funkcije i varijansu, potrebno je da odredimo aposteriornu raspodelu $f(x)|Y = f(X)$, gde su X do sada uzorkovane tačke, a Y odgovarajuće vrednosti funkcije f. Pošto pretpostavljamo da je $Y \sim \mathcal{N}_n(0, K(X, X))$, za novu tačku $(y = f(x), x)$ važi:

$$\begin{pmatrix} y \\ Y \end{pmatrix} \sim \mathcal{N}\left(\begin{pmatrix} 0 \\ 0 \end{pmatrix}, \begin{pmatrix} K(x,x) & K(X,x)^\top \\ K(X,x) & K(X,X) \end{pmatrix}\right)$$

Želimo da odredimo raspodelu $y|Y$. Za višedimenzione normalne raspodele date u obliku:

$$\begin{pmatrix} x \\ y \end{pmatrix} \sim \mathcal{N}\left(\begin{pmatrix} \mu_x \\ \mu_y \end{pmatrix}, \begin{pmatrix} A & C^\top \\ C & B \end{pmatrix}\right)$$

poznato je (Williams i Rasmussen 2006.) da važi:

$$x|y \sim \mathcal{N}(\mu_x + C^\top B^{-1}(y - \mu_y), A - C^\top B^{-1} C)$$

U našem slučaju to daje:

$$y|Y \sim \mathcal{N}(K(X,x)^\top K(X,X)^{-1} Y, K(x,x) - K(X,x)^\top K(X,X)^{-1} K(X,x))$$

što možemo zapisati i kao:

$$\begin{aligned} \mu(x) &= K(X,x)^\top K(X,X)^{-1} Y \\ \sigma^2(x) &= K(x,x) - K(X,x)^\top K(X,X)^{-1} K(X,x) \end{aligned} \tag{1}$$

Time dobijamo aposteriornu raspodelu, koju ćemo nadalje koristiti kako bismo odredili najpovoljniji deo prostora da uzorkujemo narednu tačku.

2.2 Akviziciona funkcija, EI

GP regresijom dobijamo aposteriornu raspodelu $f(x) \mid Y$. Sledeći korak je da, na osnovu te raspodele, izaberemo novu tačku u kojoj evaluiramo f. Pri toj odluci balansiramo između „is-

traživanja" delova funkcije koji nisu dobro poznati (velika varijansa) i eksploatacije delova u kojima je varijansa manja, a očekivana vrednost mala (Explore – Exploit dilemma). Za to koristimo tzv. akvizicionu funkciju (*Acquisition function*).

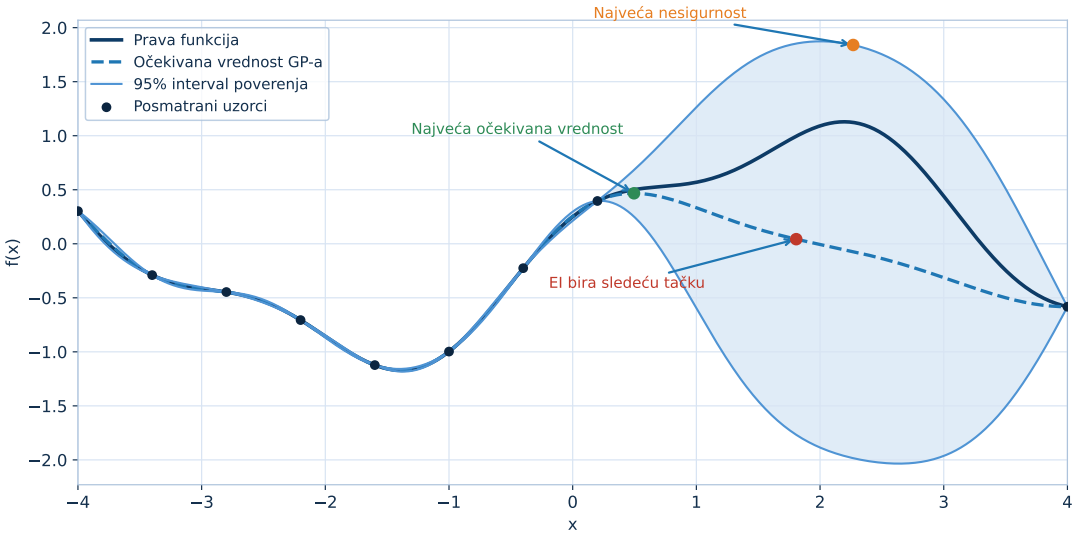

Slika 3: Explore-Exploit dilema u Bajesovskoj optimizaciji

U ovom radu koristimo princip očekivanog poboljšanja (EI – *Expected Improvement*). Neka je trenutna najbolja viđena vrednost $m = \min_{i=1,\ldots,n}(y_i)$ (minimizujemo f). Za problem minimizacije prirodno je definisati poboljšanje u tački x kao

$$I(x) = \max(m - f(x), 0).$$

Očekivano poboljšanje je onda:

$$\mathrm{EI}(x) = \mathbb{E}[I(x) \mid Y] = \mathbb{E}[\max(m - f(x), 0) \mid Y].$$

Označimo slučajnu promenljivu

$$F := f(x) \mid Y \sim \mathcal{N}(\mu(x), \sigma^2(x)).$$

Tada je:

$$\mathrm{EI}(x) = \int_{-\infty}^{+\infty} \max(m - u, 0)\, f_F(u)\, du.$$

Pošto je $\max(m - u, 0) = 0$ za $u > m$, integral se svodi na

$$\mathrm{EI}(x) = \int_{-\infty}^{m} (m - u)\, f_F(u)\, du = m \int_{-\infty}^{m} f_F(u)\, du - \int_{-\infty}^{m} u\, f_F(u)\, du.$$

Pošto je $f_F(u)$ gustina normalne raspodele $\mathcal{N}(\mu(x), \sigma^2(x))$, ovaj integral se može svesti (Snoek,

Larochelle i Adams 2012.) na sledeći oblik:

$$\mathrm{EI}(x) = (m - \mu(x))F_Z(z) + \sigma(x)f_Z(z)$$

gde je $Z \sim \mathcal{N}(0,1)$, F_Z je njegova kumulativna funkcija raspodele, f_Z njegova gustina, i $z = \frac{m-\mu(x)}{\sigma(x)}$.

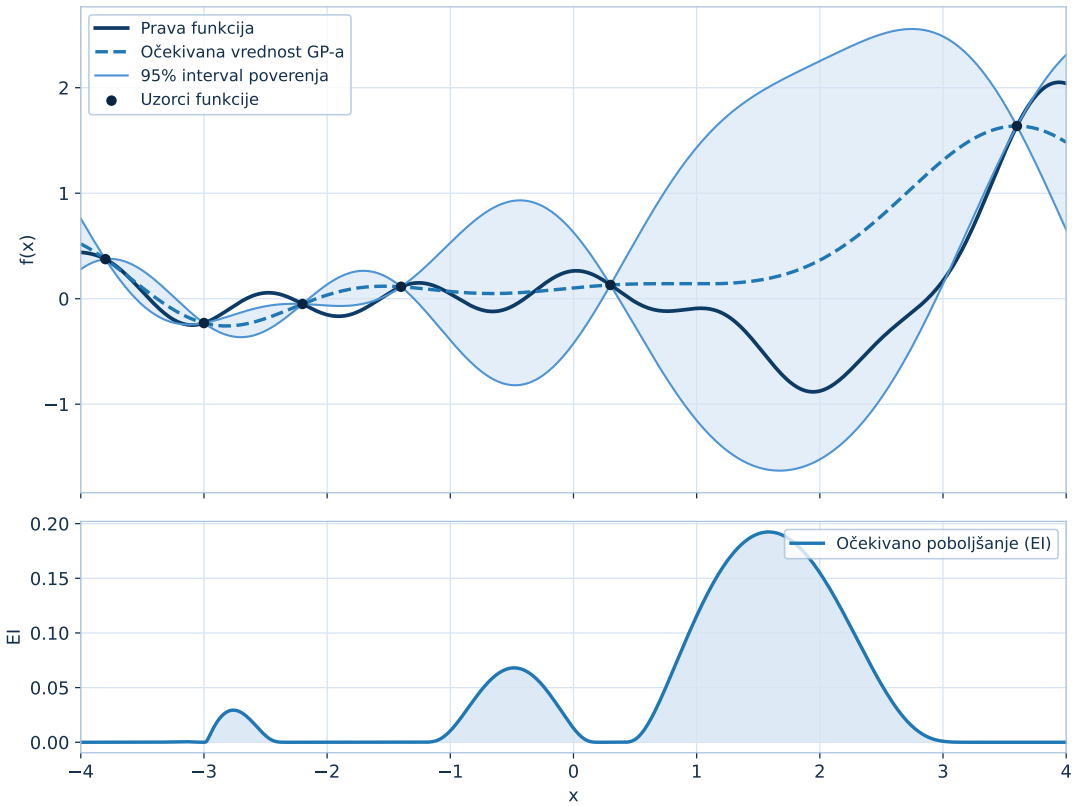

Slika 4: Primer vrednosti očekivanog poboljšanja za jednodimenzionu funkciju

Sledeću tačku biramo maksimizacijom EI na domenu:

$$x_{n+1} = \arg\max_{x \in D} \mathrm{EI}(x).$$

3 Implementacija

3.1 Opšta procedura optimizacije

Kada se Bajesovska optimizacija implementira pomoću Gausovog procesa i akvizicione funkcije očekivanog poboljšanja, dobijamo sledeći algoritam:

Algoritam 1 Bayesian optimization sa GP i EI (minimizacija)

Ulaz: funkcija f, budžet N, kernel $K(x, y)$

$X = \{\}$
$Y = \{\}$
for $t = 1$ **to** N **do**
    $\mu(x), \sigma(x) \leftarrow \text{fit_gp}(X, Y, K)$
    $x_t \leftarrow \arg\max_{x \in D} \text{EI}(x, \mu(x), \sigma(x))$
    $y_t \leftarrow f(x_t)$
    $X \leftarrow X \cup \{x_t\}, \quad Y \leftarrow Y \cup \{y_t\}$
end for
$x_{\text{best}} \leftarrow \arg\min_{x_i \in X} f(x_i)$
return $x_{\text{best}}, \ \min(Y)$

U algoritmu 1 ostaje da definišemo način maksimizacije akvizicione funkcije EI. Kao što je pokazano u 2.2, izračunavanje EI u zadatoj tački je relativno jednostavno. Međutim, kao što se vidi na slici 4, sama EI funkcija u opštem slučaju nema pogodan oblik za direktnu maksimizaciju. Zato se za njenu optimizaciju koristi zaseban optimizacioni metod. Jedna od metoda koja se koristi u praksi (Balandat i dr. 2020.) je L-BFGS. U ovom projektu L-BFGS pokrećemo više puta iz različitih početnih tačaka kako bismo povećali verovatnoću pronalaska dobrog maksimuma EI funkcije.

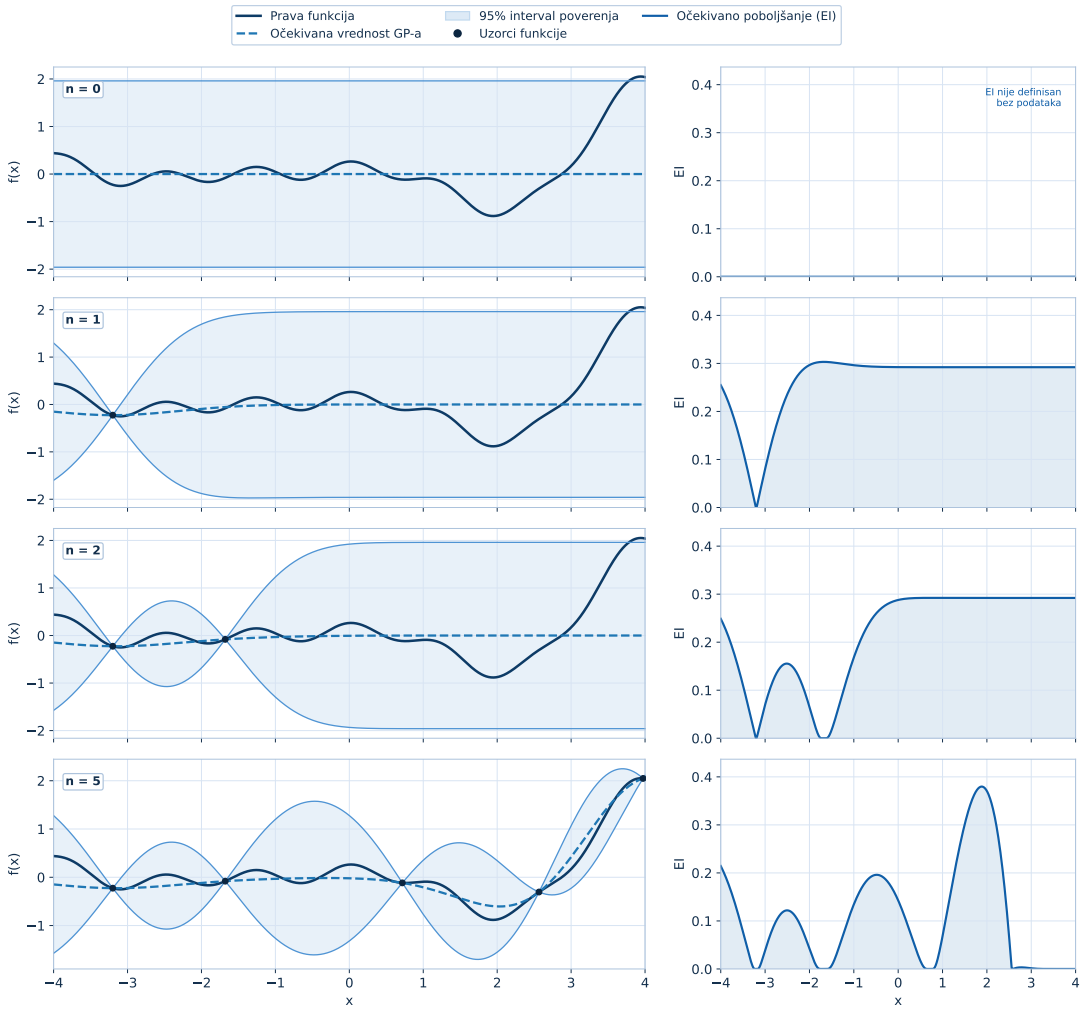

Slika 5: Primer celokupnog izvršavanja algoritma Bajesovske optimizacije za minimizaciju 1D funkcije. Prikaz u trenucima kada je uzorkovano $n = 0, 1, 4$ i 10 tačaka.

3.2 Implementacija GP regresije

Kao što je pokazano u 1 aposteriorna srednja vrednost i varijansa imaju oblik:

$$\mu(x) = m_0 + K(x, X)^\top K(X, X)^{-1}(y - m_0\mathbf{I}), \tag{2}$$

$$\sigma^2(x) = K(x, x) - K(x, X)^\top K(X, X)^{-1} K(x, X). \tag{3}$$

Direktno računanje inverza matrice u (2) i (3) je numerički nepovoljno, pa u implementaciji koristimo ekvivalentnu formu zasnovanu na Cholesky faktorizaciji. Neka je $X \in \mathbb{R}^{n\times d}$ skup tačaka u kojima je uzorkovana funkcija, $y \in \mathbb{R}^n$ vektor vrednosti funkcije u tim tačkama i $K = K(X, X)$. Kako je $K(\cdot, \cdot)$ kernel onda je i matrica K pozitivno semidefinitna pa ima Cholesky dekompoziciju:

$$K = LL^\top.$$

U izrazu (2) pojavljuje se vektor

$$\alpha = K^{-1}(y - m_0\mathbf{I}).$$

Umesto eksplicitnog inverza, α dobijamo rešavanjem dva trougaona sistema:

$$\begin{aligned} Lv &= y - m_0\mathbf{I}, \\ L^\top\alpha &= v. \end{aligned}$$

Predikcija (srednja vrednost). Za bilo koju upitnu tačku x važi

$$\mu(x) = m_0 + K(x, X)^\top \alpha.$$

Predikcija (varijansa). Formula (3) sadrži kvadratnu formu

$$K(x, X)^\top K^{-1} K(x, X).$$

Označimo $k_x = K(x, X) \in \mathbb{R}^n$. Ako rešimo sistem

$$Lw = k_x$$

onda je $w = L^{-1}k_x$ i važi

$$\begin{aligned} k_x^\top K^{-1} k_x &= k_x^\top (LL^\top)^{-1} k_x \\ &= k_x^\top L^{-\top} L^{-1} k_x \\ &= (L^{-1}k_x)^\top (L^{-1}k_x) \\ &= \|L^{-1}k_x\|_2^2 \;=\; \|w\|_2^2. \end{aligned}$$

Pa $\sigma^2(x)$ nalazimo kao:

$$\sigma^2(x) = K(x,x) - \|w\|_2^2, \qquad \text{gde je } Lw = K(x,X).$$

gde w određujemo rešavanjem trougaonog sistema: $Lw = K(x,X)$.

4 Eksperimenti

4.1 Postavka

Za evaluaciju implementacije koristili smo BBOB (blackbox optimization bechmarking) referentni test za poređenje metoda za black box optimizaciju. Test se sastoji od raznovrsnih funkcija koje je potrebno minimizovati u što manjem broju evaluacija. Svaka funkcija je napravljena tako da postoji njena varijanta u n dimenzija, pa tako mogu da se testiraju performanse metoda u različitom broju dimenzija. Takođe, za svaku funkciju postoji više njenih instanci, koje predstavljaju istu funkciju samo transliranu u prostoru. Ovo smanjuje šanse da neka metoda slučajno daje dobre rezultate na specifičnom primeru, ali ne i uopšteno za taj tip funkcije.

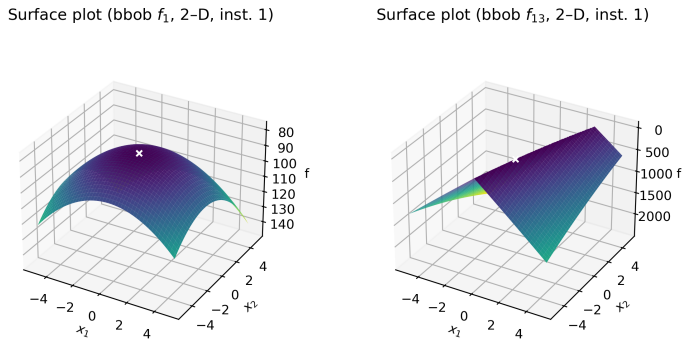

(a) Sphere (b) Sharp ridge

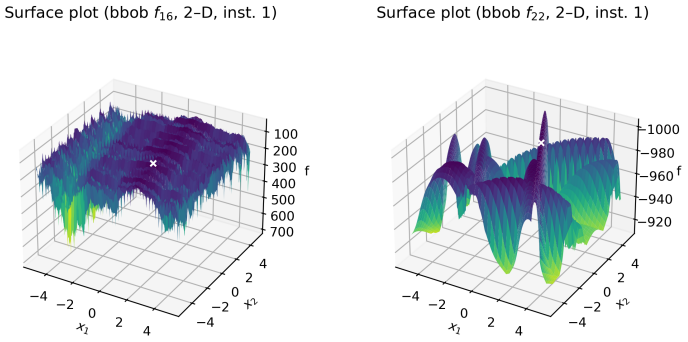

(c) Weierstrass (d) Gallagher 21 peaks

Slika 6: Grafici nekih funkcija (varijante sa dvodimenzionim domenom) iz BBOB testa. Sa X je označena pozicija optimuma.

Metode se evaluiraju tako što se za svaku funkciju postavlja redom ciljana preciznost iz nekog opsega – koliko blizu optimalnog rešenja metoda mora da nađe da bi se uzelo da je optimizacija uspešna. Ova preciznost za svaku funkciju uzima vrednosti od 100 pa sve do 10^{-8}, čime se kontroliše težina optimizacionog problema. Što je ciljano odstupanje od optimuma postavljeno niže, to očekujemo za neku metodu da će joj biti potrebno više evaluacija funkcije da bi dostiglo to odstupanje.

Ideja je da bi dobre metode za optimizaciju trebalo da često uspešno optimizuju date funkcije i da to urade u malom broju evaluacija. Variranjem tolerancije i instanci funkcija možemo da posmatramo koji procenat funkcija i njoj pridruženih ciljanih preciznosti je metoda uspešno optimizovala za neko ograničenje za broj evaluacija (budžet). Ovu zavisnost između udela uspešnosti i budžeta evaluacije nazivamo profil izvršavanja, i možemo je predstaviti na grafiku. Kada poredimo dve metode, očekujemo da za isti budžet bolji metod uspešno optimizuje veći udeo, tj. da je na grafiku "iznad".

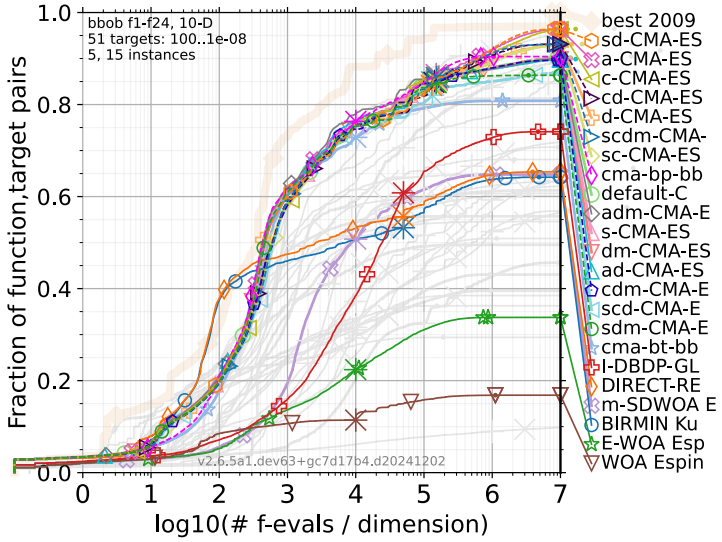

Slika 7: Primer poređenja profila izvršavanja raznih metoda iz literature do 2023. godine

4.2 Rezultati

U ovom radu smo našu implementaciju Gausovske optimizacije poredili sa dve druge metode: - Nasumična pretraga – nasumično generišemo tačke unutar domena u kojima evaluiramo funkciju i beležimo najbolje nađenu - Optuna GPSampler – referentna implementacija uzorkovanja vođeno Gausovskim procesom, deo često korišćene biblioteke Optuna

Za generisanje rezultata korišćene su biblioteke coco-experiment za pokretanje metoda na BBOB testu i coco-postprocess za prikazivanje i generisanje grafika profila izvršavanja.

Napomena: da bi se evaluacija završila u razumnom vremenu na našem hardveru, svaka metoda je kao maksimalan budžet imala $40d$ evaluacija, gde je d broj dimenzija trenutne funkcije. Postavljeni maksimalan budžet dovodi do odsecanja izvršavanja posle određenog ukupnog broja evaluacija, pa sve nakon tog trenutka ne može da uveća broj uspeha, što se na grafiku vidi kao

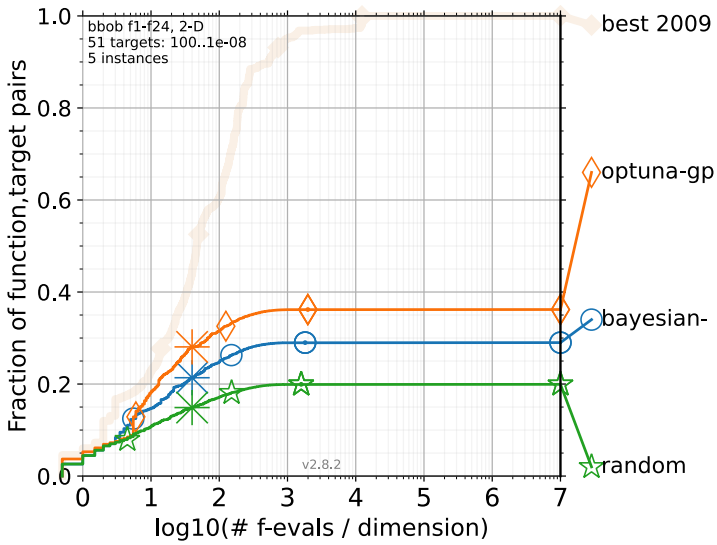

Slika 8: Poređenje profila izvršavanja Optuna GPSampler-a (zeleno), Nasumične pretrage (narandžasto) i naše implementacije Bajesovske optimizacije (plavo)

asimptota.

4.3 Diskusija

5 Zaključak

Literatura

Booker, Andrew J i dr. (1999.). „A rigorous framework for optimization of expensive functions by surrogates". U: *Structural optimization* 17.1, str. 1–13.

Williams, Christopher KI i Carl Edward Rasmussen (2006.). *Gaussian processes for machine learning*. Sv. 2. 3. MIT press Cambridge, MA.

Snoek, Jasper, Hugo Larochelle i Ryan P Adams (2012.). „Practical bayesian optimization of machine learning algorithms". U: *Advances in neural information processing systems* 25.

Frazier, Peter I. (2018.). *A Tutorial on Bayesian Optimization*. arXiv: `1807.02811 [stat.ML]`. URL: `https://arxiv.org/abs/1807.02811`.

Balandat, Maximilian i dr. (2020.). „BoTorch: A framework for efficient Monte-Carlo Bayesian optimization". U: *Advances in neural information processing systems* 33, str. 21524–21538.